

Projeto Final de Ciência de Dados para Engenheiros

Relatório Técnico – Módulo 1

Vinícius César Sena Torres – RA 22409225

11 de novembro de 2025

Resumo

Este relatório documenta o módulo de clusterização hierárquica aplicado à base de 550.068 transações do Walmart. A análise exploratória inicial demonstrou ticket médio de R\$9.263,97, mediana de R\$8.047,00 e coeficiente de assimetria 0,60, confirmando a presença de cauda longa no gasto. Após o pré-processamento, as variáveis comportamentais foram normalizadas e reduzidas por PCA, possibilitando agrupar 5.891 usuários em macroperfis com interpretação de negócio clara.

1 Introdução

A etapa de EDA mostrou que os usuários realizam compras em 3.631 produtos distribuídos em vinte categorias, sendo as mais recorrentes 5, 1 e 8 (juntas, 73% das transações). As cidades do tipo C foram responsáveis pelo ticket médio mais alto (R\$9.719,92), reforçando a necessidade de segmentar clientes segundo intensidade e variedade de consumo. O objetivo deste módulo é traduzir esses padrões em clusters estatisticamente defensáveis para embasar personalização, campanhas e recomendações.

2 Metodologia

Foram executadas as seguintes etapas:

- **Análise exploratória:** consolidação de estatísticas descritivas, distribuição por faixa etária/gênero e avaliação de cauda longa para justificar métricas robustas.
- **Pré-processamento:** imputação de *Product_Category* faltante com -1, transformação de *Stay_In_Current_City_Years* para valores numéricos e codificação ordinal das faixas etárias.

- **Engenharia de atributos:** agregação por usuário gerando métricas de volume (total de compras, gasto acumulado), intensidade (ticket médio, desvio) e variedade (produtos/categorias únicas), além da participação nas cinco categorias mais vendidas (5, 1, 8, 11 e 2).
- **Normalização e PCA:** padronização por *z-score* e redução para 12 componentes principais, suficientes para explicar 92,6% da variância acumulada.
- **Clusterização:** aplicação do método aglomerativo de Ward (distância euclidiana). A silhueta foi calculada para $k \in [2, 6]$; o melhor valor foi $k = 2$, com silhueta 0,19, adequado para macrosegmentação.

3 Resultados e Discussão

A Tabela 1 sintetiza os segmentos encontrados.

Tabela 1: Síntese dos clusters hierárquicos

Cluster	Usuários (%)	Compras méd.	Total gasto méd. (R\$)	Ticket méd. (R\$)	Cat. ún
C0	86,7	62,7	602.398,13	9.676,59	8,8
C1	13,3	293,8	2.578.241,51	8.865,92	14,5

O **Cluster C0** (86,7% dos usuários) reúne compradores casuais: média de 63 compras distribuídas ao longo de quase dois anos (41,8 compras/ano) e ticket médio de R\$9.676,59. A participação em categorias é equilibrada entre 5 (32,0%), 1 (31,8%) e 8 (26,2%), em linha com o que foi observado na EDA. Aproximadamente 71% dos integrantes são homens e a idade média codificada (2,69) aponta para as faixas de 26–45 anos.

O **Cluster C1** (13,3%) concentra os *heavy users*: média de 294 compras (mais de 202 compras/ano), gasto acumulado quatro vezes maior que o grupo casual e variedade de 14,6 categorias. Embora o ticket médio unitário seja ligeiramente menor, o volume compensa e justifica benefícios de fidelidade. A categoria 5 responde por 35,6% da cesta e a presença masculina chega a 76%, indicando afinidade com combos premium.

O dendrograma reforça a separação em dois níveis: primeiro isolam-se consumidores de altíssima recorrência (C1) e, posteriormente, subdivisões de menor estabilidade em C0. Apesar da silhueta absoluta moderada, as métricas de volume, variedade e composição demográfica sustentam a segmentação macro.

4 Recomendações

1. Oferecer benefícios progressivos (frete grátis, pré-lançamentos) ao Cluster C1, que sozinho movimenta mais de $R\$2,5 \times 10^6$ por usuário.

2. Para o Cluster C0, trabalhar kits pré-montados envolvendo categorias 1, 5 e 8, buscando elevar a variedade média de 8,9 para níveis próximos aos heavy users.
3. Monitorar trimestralmente as componentes principais: variações acima de 5% na variância explicada indicarão mudanças estruturais na cesta e possíveis reclassificações.

5 Conclusão

A combinação de EDA e clusterização hierárquica revelou dois perfis dominantes: compradores ocasionais de alto ticket por evento e heavy users extremamente frequentes. O pipeline (pré-processamento, PCA e validação com silhueta) assegura rastreabilidade e fornece insumos objetivos para campanhas, recomendações e monitoramento contínuo do comportamento de consumo.